

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



**XÂY DỰNG HỆ THỐNG RAG HỎI ĐÁP
QUY CHẾ ĐÀO TẠO & TUYỂN SINH ĐẠI HỌC**

BÁO CÁO BÀI TẬP 02

Học phần: AIT3009# 1

Sinh viên thực hiện

Nguyễn Thị Thanh Huyền - 23020381

Nguyễn Thị Minh Ly - 23020399

Đặng Minh Nguyệt - 23020407

Giảng viên hướng dẫn

ThS. Ngô Minh Hương

HÀ NỘI - 2026

1 Dữ liệu và Mô hình

1.1 Xây dựng dữ liệu

1.1.1 Thu thập tài liệu

Nhóm thu thập dữ liệu từ 4 nguồn chính thức của VNU-UNET:

- **Wikipedia tiếng Việt** - bài viết về ĐHQGHN và UET (lịch sử thành lập, cơ cấu tổ chức, thành tích nghiên cứu).
- **Đề án Tuyển sinh UET năm học 2026 - 2027** (PDF) - thông tin tuyển sinh 2026 - 2027, chỉ tiêu, điểm chuẩn, học phí theo từng ngành.
- **Sổ tay sinh viên UET** (PDF) - quy trình đăng ký học phần, xử lý học vụ, cảnh báo học vụ, thủ tục nhập học.
- **Quy chế đào tạo UET** (PDF) - điều kiện tốt nghiệp, điểm thưởng NCKH, miễn học phần ngoại ngữ.

Lý do lựa chọn: các nguồn này bao phủ toàn bộ nhu cầu hỏi đáp thực tế của sinh viên VNU-UNET. Các công cụ trích xuất được sử dụng là `beautifulsoup4` cho HTML, `pypdf` cho PDF. Hậu kỳ thủ công bao gồm loại bỏ header/footer PDF, chuẩn hóa ký tự Unicode tiếng Việt và loại bỏ bảng biểu bị vỡ định dạng.

1.1.2 Chunking

Văn bản được chia thành các đoạn nhỏ theo chiến lược sliding window với `chunk_size=300` ký tự và `chunk_overlap=50` ký tự. Mỗi chunk được gán `title` từ tài liệu gốc, hỗ trợ BM25 matching khi tiêu đề chứa từ khóa quan trọng. Kết quả là **2157 chunks** với cấu trúc `{chunk_id, title, text}`.

1.1.3 Gán nhãn dữ liệu

Nhóm xây dựng tập test gồm **50 câu hỏi** theo tiêu chí đa dạng chủ đề và độ khó:

Bảng 1: Phân bố câu hỏi tập test theo chủ đề

Chủ đề	Số câu	Tỉ lệ
Lịch sử VNU-UNET	12	24%
Tuyển sinh 2026	15	30%
Học phí	8	16%
Quy chế & học vụ	15	30%
Tổng	50	100%

Mỗi câu hỏi được gán nhãn với **reference_answer** (chuỗi câu trả lời chuẩn) và **relevant_chunk_ids** (danh sách index chunk chứa thông tin). Quy trình gán nhãn: từng thành viên gán nhãn độc lập trên Google Sheets, sau đó cả nhóm họp thống nhất các trường hợp bất đồng.

1.1.4 Đánh giá chất lượng gán nhãn (IAA)


Nhóm chọn ngẫu nhiên 20 câu (40% tập test) để 2 thành viên gán nhãn độc lập, đo IAA bằng Cohen's Kappa trên **relevant_chunk_ids**:

Bảng 2: Inter-Annotator Agreement (Cohen's Kappa)

Cặp annotator	Cohen's Kappa
Huyền – Ly	0.74
Ly – Nguyệt	0.71
Trung bình	0.73

Kappa = 0.73 thuộc mức *substantial agreement*, cho thấy tiêu chí gán nhãn đủ rõ ràng và nhất quán giữa các thành viên.

1.2 Kiến trúc hệ thống



Hình 1: Kiến trúc tổng thể hệ thống Advanced Hybrid RAG

Hệ thống gồm 5 module chính được mô tả trong Hình 1:

(1) **Query Processing:** Chuẩn hóa câu hỏi đầu vào - lowercase, loại bỏ dấu câu thừa, mở rộng 25+ viết tắt tiếng Việt (DHQGHN, CNTT, TTNT, v.v.) và bổ sung từ đồng nghĩa cho 20+ nhóm khái niệm học vụ/tuyển sinh.

(2) **Query Rewriting:** Dùng chính Qwen2.5-3B sinh 2-3 biến thể câu hỏi diễn đạt khác nhau, sau đó retrieve song song trên tất cả biến thể. Chiến lược này giúp tăng recall với câu hỏi có nhiều cách diễn đạt.

(3) **Hybrid Retrieval:** Với mỗi biến thể câu hỏi, thực hiện song song:

- *BM25 sparse retrieval* - khớp từ khoá chính xác, hiệu quả với số năm, mã ngành, số điều khoản.
- *FAISS dense retrieval* - tìm kiếm ngữ nghĩa với multilingual-MiniLM-L12-v2 (dim=384).

(4) **RRF Fusion:** Hợp nhất tất cả danh sách xếp hạng từ BM25 và FAISS của mọi biến thể câu hỏi bằng RRF ($k = 60$), chọn top-5 chunks.

(5) **Generative Reader:** Qwen2.5-3B-Instruct GGUF Q4_K_M nhận top-3 chunks làm context, sinh câu trả lời bằng tiếng Việt. Prompt được thiết kế theo chat template <|im_start|> của Qwen với 4 quy tắc ràng buộc: chỉ dùng thông tin trong tài liệu, trả lời 1-2 câu, không giải thích thêm, trả lời UNKNOWN nếu không có thông tin.

1.3 Các biến thể thử nghiệm

Bảng 3: Mô tả các biến thể hệ thống

Hệ thống	Mô tả
Baseline (BM25)	Sparse retrieval thuần, không dùng embedder hay LLM rewriting. Baseline đơn giản nhất, không yêu cầu GPU.
Dense RAG (FAISS)	Chỉ dùng FAISS với embedder đa ngữ. Đánh giá khả năng semantic search độc lập.
Advanced Hybrid	BM25 + FAISS + Query Rewriting + RRF. Hệ thống đề xuất của nhóm.

Lý do lựa chọn thiết kế:

- **Hybrid thay vì single retriever:** BM25 mạnh với số liệu chính xác (97/CP, CN12, 1.9GB); FAISS mạnh với câu hỏi diễn đạt khác cấu trúc tài liệu. Kết hợp bổ sung nhược điểm lẫn nhau.
- **RRF thay vì weighted sum:** BM25 score và cosine similarity có thang đo khác nhau về bản chất. RRF chỉ dùng thứ hạng, tránh vấn đề calibration.

- **GGUF Q4_K_M:** Full precision Qwen2.5-3B cần ~6GB RAM, vượt giới hạn thực nghiệm (8GB). Q4_K_M giảm xuống ~1.9GB với độ suy giảm chất lượng tối thiểu.
- **Generative thay vì extractive:** Nhóm thử nghiệm letrunglinh/qa_pnc (extractive) nhưng EM chỉ đạt 0.15, F1 = 0.42 - model chỉ copy span từ một chunk, không tổng hợp được câu trả lời từ nhiều nguồn. Chuyển sang generative reader cải thiện F1 lên 0.60.

2 Kết quả thực nghiệm và Phân tích

2.1 Thiết lập thực nghiệm

- **Phần mềm:** Python 3.11, llama-cpp-python 0.3.2, sentence-transformers 2.5.1, faiss-cpu 1.8.0, rank_bm25 0.2.2.
- **Tham số:** top_k=5, max_new_tokens=150, n_ctx=1024, n_threads=4.

2.2 Phase 1 - Retrieval Benchmark

Bảng 4: Kết quả Retrieval Benchmark (Recall@K)

Hệ thống	Recall@1	Recall@3	Recall@5
Dense only (FAISS)	0.38	0.52	0.54
Advanced Hybrid	0.64	0.84	0.92

Advanced Hybrid vượt Dense về Recall@5 **+38 điểm phần trăm**. Dense retrieval yếu (0.54) do embedder không encode tốt các thực thể đặc thù như mã nghị định, mã ngành, địa chỉ email - những token mà BM25 khớp chính xác.

2.3 Phase 2 - QA Benchmark

Bảng 5: Kết quả QA Benchmark (EM / F1 trên 50 câu hỏi test)

Hệ thống	Exact Match	F1 Score
Baseline (BM25)	0.20	0.575
Dense RAG (FAISS)	0.18	0.393
Advanced Hybrid RAG	0.24	0.604

EM thấp hơn F1 do generative model diễn đạt linh hoạt hơn reference answer. Bootstrap resampling ($n=1000$) xác nhận Advanced vs Dense có ý nghĩa thống kê ($\Delta F1=+0.211$, $p < 0.01$, 95% CI: $[+0.134, +0.289]$); Advanced vs Baseline không có ý nghĩa thống kê ($p = 0.31$).

2.4 Phân tích theo nhóm câu hỏi

Bảng 6: F1 Score theo nhóm câu hỏi

Nhóm	Số câu	Advanced F1	Dense F1
Lịch sử VNU-UET	12	0.71	0.38
Tuyển sinh 2026	15	0.65	0.42
Học phí	8	0.58	0.31
Quy chế & học vụ	15	0.52	0.41
Trung bình	50	0.604	0.393

Câu hỏi lịch sử hưởng lợi nhiều nhất từ BM25 (+0.33 F1) vì chứa số năm và tên riêng. Câu hỏi quy chế khó nhất do câu trả lời thường rải rác ở 2-3 chunk liên tiếp bị cắt bởi chunking.

2.5 RAG vs Closed-Book

Câu hỏi về số liệu cụ thể (học phí, điểm chuẩn, mã ngành) không thể trả lời đúng không có RAG - LLM hallucinate hoặc trả về "UNKNOWN". Câu hỏi định nghĩa chung LLM có thể trả lời gần đúng nhưng thiếu chi tiết đặc thù (mã QH, số lượng trường thành viên hiện tại).

2.6 Ví dụ output thực tế

Ví dụ 1 - Advanced thành công, Dense thất bại (câu hỏi số liệu chính xác):

Bảng 7: Ví dụ câu hỏi về số liệu


Câu hỏi	Nghị định 97/CP ngày 10/12/1993 sáp nhập những trường nào để thành lập VNU?
Reference	DH Tổng hợp HN, DH Sư phạm HN I và DH Sư phạm Ngoại ngữ HN.
Advanced	DH Tổng hợp HN, DH Sư phạm HN I và DH Sư phạm Ngoại ngữ HN. ($F1=1.0$)
Dense	DHQGHN thành lập trên cơ sở sáp nhập một số trường đại học lớn. ($F1=0.21$)

Ví dụ 2 - Cả hai đều trả lời, Advanced chi tiết hơn (câu hỏi quy chế):

Bảng 8: Ví dụ câu hỏi về quy chế học vụ

Câu hỏi	Sinh viên bị cảnh báo học vụ khi nào?
Reference	Khi điểm trung bình tích lũy dưới mức quy định.
Advanced	Khi ĐTBTL dưới 1.20 (năm 1), 1.40 (năm 2) hoặc 1.60 (từ năm 3). ($F1=0.68$)
Dense	Khi điểm trung bình học kỳ thấp hơn quy định. ($F1=0.52$)

2.7 Demo hệ thống



Hình 2: Giao diện demo VNU-UET RAG Assistant (Flask + HTML)

2.8 Phân tích lỗi

- **Chunk boundary** ($\sim 37\%$ miss): câu trả lời nằm ở ranh giới 2 chunk, reader nhận nửa thông tin.
- **Ground truth index sai** ($\sim 25\%$ miss): sửa lại giúp Recall@5 tăng từ 0.84 lên 0.92.
- **Query expansion nhiều** ($\sim 38\%$ miss): synonym quá rộng kéo chunk không liên quan lên top.

3 Kết luận

Báo cáo này trình bày hệ thống Advanced Hybrid RAG cho bài toán hỏi đáp về quy chế đào tạo và tuyển sinh VNU-UET. Hệ thống kết hợp BM25 sparse retrieval, FAISS dense retrieval, Reciprocal Rank Fusion và Qwen2.5-3B-Instruct generative reader, đạt Recall@5 = **0.92** và F1 = **0.604** trên tập test 50 câu hỏi tiếng Việt.

Các kết quả chính:

- Hybrid retrieval vượt dense retrieval đơn lẻ +38% Recall@5, xác nhận sự bổ sung lẫn nhau giữa sparse và dense retrieval trên dữ liệu tiếng Việt chuyên ngành.
- Generative reader vượt trội extractive reader (+0.38 F1) do khả năng tổng hợp thông tin từ nhiều chunk.
- Hệ thống chạy hoàn toàn trên CPU 8GB RAM với thời gian phản hồi ~10–20 giây/câu, không yêu cầu GPU hay API thương mại.

Hạn chế và hướng phát triển:

- Tốc độ inference chậm trên CPU - có thể cải thiện bằng GPU hoặc mô hình nhỏ hơn (1.5B).
- Chunk boundary vẫn là lỗi phổ biến nhất - cần thử nghiệm chiến lược chunking theo ngữ nghĩa (semantic chunking).
- Chưa đánh giá trên câu hỏi đa hop (multi-hop) yêu cầu tổng hợp thông tin từ nhiều tài liệu khác nhau.
- Hướng tiếp theo: fine-tuning embedder trên dữ liệu tiếng Việt chuyên ngành để cải thiện dense retrieval.